

Prédiction des ventes hebdomadaires des magasins Walmart

Optimisation des campagnes marketing grâce à la modélisation prédictive


Contexte : Walmart veut anticiper ses ventes pour allouer son budget marketing.

Objectif : Construire un modèle de régression linéaire régularisé permettant d'estimer les ventes à partir d'indicateurs économiques et contextuels.






Enjeux métier : Identifier les leviers clés (CPI, chômage, saisonnalité, magasins) et fournir un outil d'aide à la décision.

Donnés & EDA


- - 150 LIGNES x 8 colonnes au chargement => 136 lignes après suppression de la cible manquante
- - 20 magasins (Store 1 à 20), période 2010-2012, 85 dates uniques
- Cible : Weekly_Sales
- Prédicateurs bruts : Store, Date, Holiday_Flag, Temperature, Fuel_Price, CPI, Unemployment
- Valeurs manquantes : 5 à 8 % selon la colonne
- Distributions des ventes étalée, avec quelques semaines exceptionnellement hautes (période de fêtes).



Histogrammes des variables numériques




Prétraitement & Pipeline



Modélisation : Régression linéaire baseline

Métrique	Train	Test	Écart
R ²	0.9702	0.9239	-0.0463
RMSE	110 435\$	183 536\$	+73 101\$
MAE	77 483\$	132 032\$	+54 549\$


Diagnostic : début d’overfitting — écart train/test visible sur les 3 métriques.



Ridge & Lasso : test de régularisation

• Tableau récapitulatif

Modèle	R ² train	R ² test	RMSE test	MAE test	α optimal
Linear	0.9702	0.9239	183 536 \$	132 032 \$	—
Ridge	0.9699	0.9227	184 977 \$	133 530 \$	0.7843
Lasso	0.9698	0.9228	184 853 \$	132 353 \$	1414.99



Interprétation métier/Recommandations

Les 10 coefficients les plus forts sont tous des Store. Certains sur-performent, d'autres sous-performent structurellement.

- 1) Approfondir l'analyse par magasin : les écarts structurels entre magasins justifient des stratégies différenciées.**
- 2) Surveiller CPI et chômage comme signaux**
- 3) Anticiper les pics saisonniers (fins d'année) pour la logistique**
- 4) Industrialiser : exposer le pipeline via API pour que les équipes puissent tester des scénarios.**

Limites & Perspectives

Limites identifiées

1. **Taille du dataset** (136 lignes après suppression des cibles manquantes) : les conclusions sont fragiles statistiquement. Une collecte sur plusieurs années et davantage de magasins serait nécessaire pour une robustesse industrielle.
2. **Split aléatoire plutôt que temporel** : justifié par le cadrage descriptif du projet, mais un test de robustesse avec split temporel serait un plus.
3. **Imputation par moyenne** : rapide mais peut introduire un léger biais. Une imputation par modèle (KNN ou régression) serait plus rigoureuse sur des jeux de données plus larges.
4. **Modèles linéaires uniquement** : des modèles non-linéaires (Random Forest, Gradient Boosting) pourraient capturer des interactions plus fines, au prix de l'interprétabilité.
5. **Corrélations faibles entre features et cible** : cela limite intrinsèquement la performance maximale atteignable.

Perspectives

- **Enrichir les données** : météo locale détaillée, événements locaux, concurrence, promotions marketing.
- **Tester des modèles non-linéaires** : forêts aléatoires, gradient boosting, en comparant rigoureusement avec la baseline linéaire.
- **Industrialisation** : conteneurisation (Docker), suivi des modèles (MLflow), exposition via API (Flask / FastAPI).
- **Test de robustesse** : reproduire l'analyse avec un split temporel pour comparer les performances.